HW1 - Odd-Even Sort

106062322 **江岷錡**

Implementation

本次實作中，強調 Odd-Even Sorting 的跨 Node 排序。首先，由於有多個 Process 可使用，因此我們進行以下處理：(假設有 `N` 筆資料與 `K` 個 Process)

1. `N < K` 時：由於目前 Process 數量大於擁有的資料，我們首先讓前面的 Process 分到 **1筆** 資料。剩餘的 Process (K > N) ，則將他們丟離 MPI_COMM 。透過 stackoverflow 的解說，我試著重新創建新的 communicate group `mpi_comm` ，並讓其餘未使用的 process ，脫離這個 group ，並將其 MPI_COMM 參數會變為 MPI_COMM_NULL。
2. `N ≥ K` 時：當大於 process 數量時，仍須考慮到無法整除的問題。根據嘗試兩種方法後，發現以：先將 `N 除以 K` ，得出的商 `s` 與餘數 `m` 。接著，讓 `m` 以前的每個 process 多分一筆資料，即可完美均分資料。

透過完整切分資料後，便可直接使用 `MPI_File_read_at` ，每個 process 找出自己的 read offset 後，將資料取出。

接著，再進行 local data 的 sorting 。在實作中，我嘗試了兩種作法： `merge sort` 、 `quick sort` 。

Sorting Method

Aa Algorithm	Best case	Worst case	Average
Quick Sort	O(n log n)	O(n2)	O(n log n)
Merge Sort	O(n log n)	O(n log n)	O(n log n)

由於在 Worst case 情況下， `merge sort` 有較低的複雜度，實際在極大測資下，也驗證出相同結果。因此最終以 merge sort 進行 local sorting 。

接著，便進入本次 Odd-Even sorting 的實作環節。若總共有 K 個 Process ，Odd-Even Sorting 最多只需執行 K 次，即可排序完成。因此，我設計一個 for-loop 迴圈，每個 phase 為一個 iteration ，並讓其最多執行 K 次。 odd-even sort 的原型如下所示：

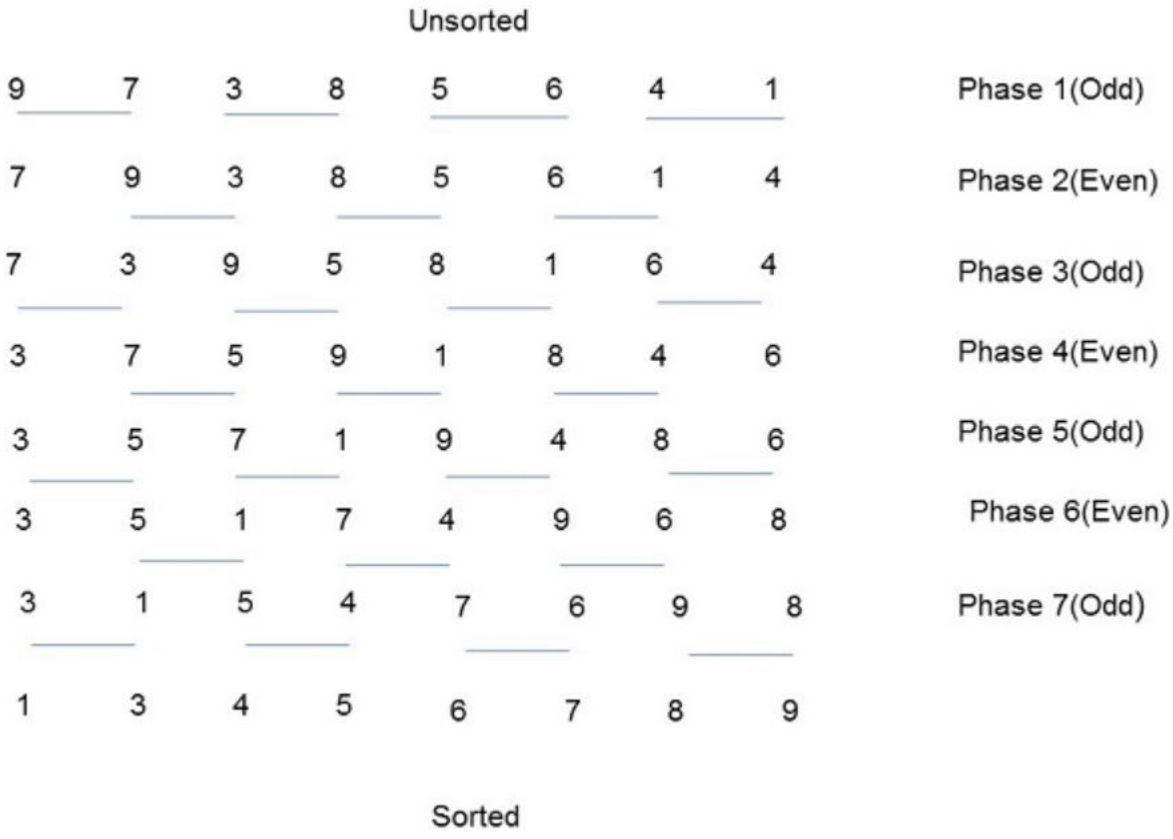

在每次 iteration 中，會先找出自己的 partner rank id ，並進行雙方的資料溝通。經過測試，我們使用 `MPI_Sendrecv` 作為溝通方式，降低 Communication overhead。同時，單次的資訊交換，就是各自將 **全部擁有的 data** 一次傳給對方，降低溝通次數。當雙方分享完各自的 **全部資料**後，每個 Process 便會開始內部的再 sorting 。

在任一 process pair 中，process 若位在左側的位置，則代表需要收集前半部的資料。

在任一 process pair 中，process 若位在右側的位置，則代表需要收集後半部的資料。

為了節省時間，此部分的 sorting 方式，則是以 `找滿了就停止` 的 sorting 技巧。舉例來說，假設我們要找前半部較少的資料，則透過遍歷以下步驟：

1. 比較自己的最小資料 ，和收到的最小資料
2. 將兩者中最小的資料塞入 `temp array` ，並進行 `index++`
3. 遍歷多次後，若 `temp array` 尚未塞滿，則分別檢查 `my_data` 與 `other_data` ，將剩餘的資料補齊。

```
int my_idx = 0, other_idx = 0, out_idx = 0;
while(out_idx < my_size) {
    if (my_idx < my_size && other_idx < other_size) {
        if(my_data[my_idx] < other_data[other_idx]) tmp[out_idx++] = my_data[my_i
dx++];
        else tmp[out_idx++] = other_data[other_idx++];
    }
    else if (my_idx < my_size) tmp[out_idx++] = my_data[my_idx++];
    else tmp[out_idx++] = other_data[other_idx++];
}
```

在我實作中，為了加快排序進程，我實作了 `early stop` 的技巧。事實上，每次要進行 sorting 前，會 **先檢查左邊的 Process 擁有的最後一筆資料，是否小於右邊 Process 擁有的第一筆資料**。

若有此情況，則代表本次不需要進行 sorting ，也就不會再進 sorting function 。而當該 phase 沒有發生任何 sorting 時，則會直接 break 迴圈，讓 Odd-Even Sort 提早結束。檢查方式是將自己有沒有 sorting 的訊息，用 `MPI_AIIreduce` 分享給所有 process ，用一次 MPI 溝通完成確認。

```
for (...) {
  int is_swap = 0;
  ...
  if (local_data[local_size - 1] > my_temp[0]) {
      merge(local_size, right_size, local_data, my_temp, LOW);
      is_swap = 1;
  }
  ...
  int sum_up = 0;
  MPI_Allreduce(&is_swap, &sum_up, 1, MPI_INT, MPI_SUM, mpi_comm);
  if (sum_up == 0 && !is_first_time) break;
}
```

最後，再透過 **MPI_File_write_at** ，將各自的資料寫回 output file ，完成本次作業要求。

Some improvements & trials

1. fewer MPI is perfect：越少的溝通次數，包括用 MPI_Allreduce 取代 MPI_reduce + MPI_Bcast，對於整體的效能有極大的幫助。

2. 降低效率的計算： `%` \ 乘除 都對計算上產生極大效能衝擊，找出替代方法進行計算，可有效提高效率。
3. Non-blocking 的疑慮：在本次實驗中，MPI 互動總共試過了 `MPI_Send` + `MPI_Recv` / `MPI_Isend` + `MPI_Irecv` / `MPI_Sendrecv` ，第二種（Non-blocking）的方法，在某些時候會導致傳輸的值 overflow ，並讓結果出錯。也因此，本次實作便不使用任何 Non-blocking 的方法。
4. Early declare function ： 由於本次實驗中有額外寫多個 Function 供呼叫，透過實驗發現將 merge sort function 用以下兩種寫法：
    1. 移到 main function 前
    2. 移到 main function 後，main function 前只做基本 function 定義

    方法一會比方法二快上 6 seconds 左右時間。

Experiment & Analysis

Methodology

System Spec

使用學校提供的 cluster

Performance Metrics

本次使用 `clock_gettime` 進行採樣 computation time, I/O time 及 communication time。由於用此 function 可達成 nanosecond 級的採樣，得以更細緻的進行表現差異的分析。

一個標準的 `clock_gettime` 範例如下：

```
struct timespec start, end, temp;
double time_used;
clock_gettime(CLOCK_MONOTONIC, &start);

....  something to be measured  ...

clock_gettime(CLOCK_MONOTONIC, &end);
if(end.tv_nsec < start.tv_nsec){
  output = ((end.tv_sec - start.tv_sec -1)+(nano+end.tv_nsec-start.tv_nsec)/nan
o);
} else {
```

```
  output = ((end.tv_sec - start.tv_sec)+(end.tv_nsec-start.tv_nsec)/nano);
}
time_used = temp.tv_sec + (double) temp.tv_nsec / 1000000000.0;

// Get what we want to evaluate
printf("%f second\n", time_used);
```

Strong Scalability

Time Profile(Multiple Nodes = 4)

	Communication	Compute	I/O	Overall
4	3.271437	1.337375	0.694561	5.303373
8	1.985527	0.705102	0.473402	3.164031
16	1.489519	0.333748	0.753885	2.577152
32	1.304226	0.153394	0.460394	1.918014
48	1.204163	0.126012	0.556855	1.88703

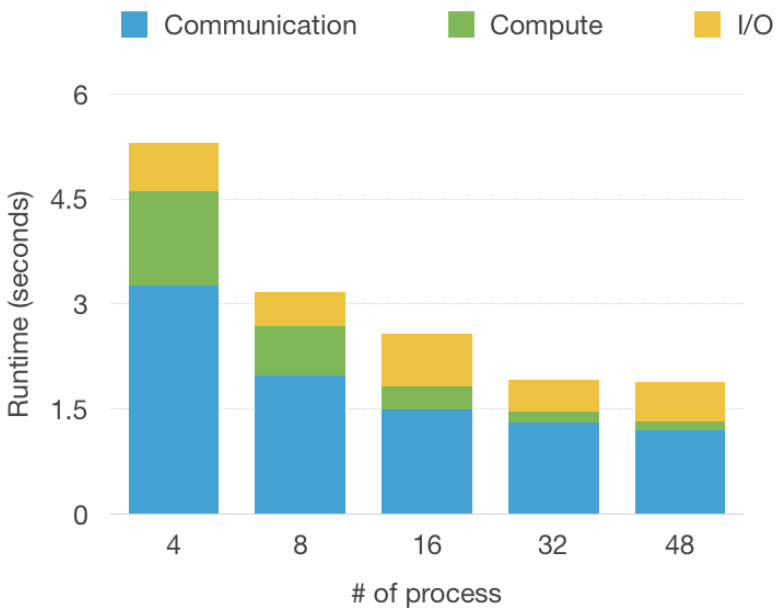

Time Profile(Single Node)

	Communication	Compute	I/O	Overall
1	0	13.527215	0.788679	14.315894
2	2.952286	5.487376	0.630761	9.070423
4	3.263282	1.406967	0.588521	5.25877
8	2.181296	0.716368	0.246197	3.143861
12	1.797199	0.492421	0.475472	2.765092

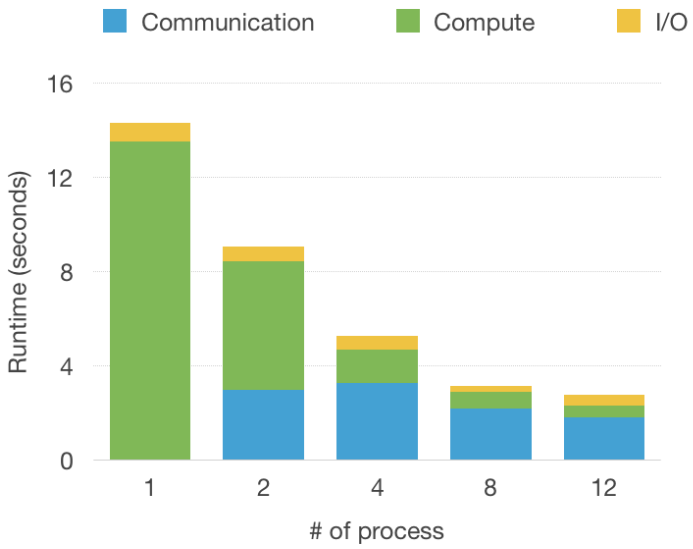

從實驗數據推測以下：

1. **Computation Time 與 Process 數量成反比**：當 Process 數量增多，單一 Process 所要處理的數據量便減少。也因此，computation time 也將逐步降低。
2. **Multi-node 時，Communication Time 緩慢下降**：當 Process 數量變多，溝通的時間也有稍微的下降，推測可能的原因，應該是單次的傳遞資料可較少，導致其現象。 **下方也透過實驗證明了這個假說。**

Speedup Factor(Multiple Nodes = 4)

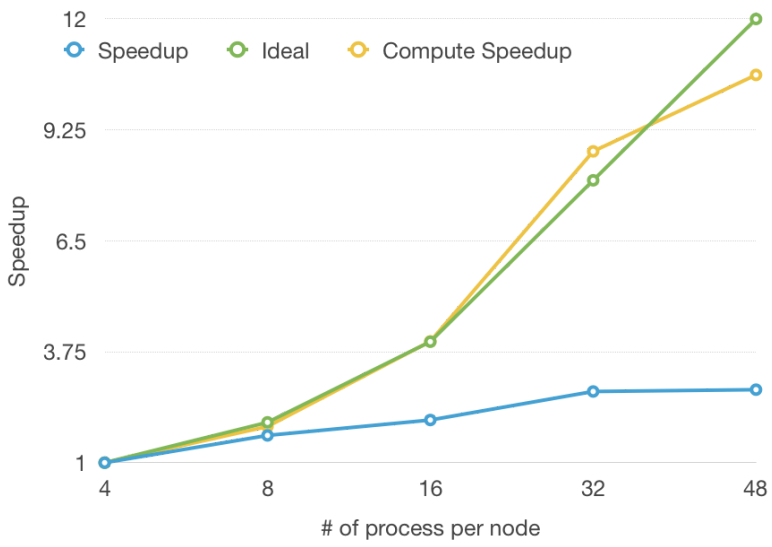

Speedup Factor(Single Node)

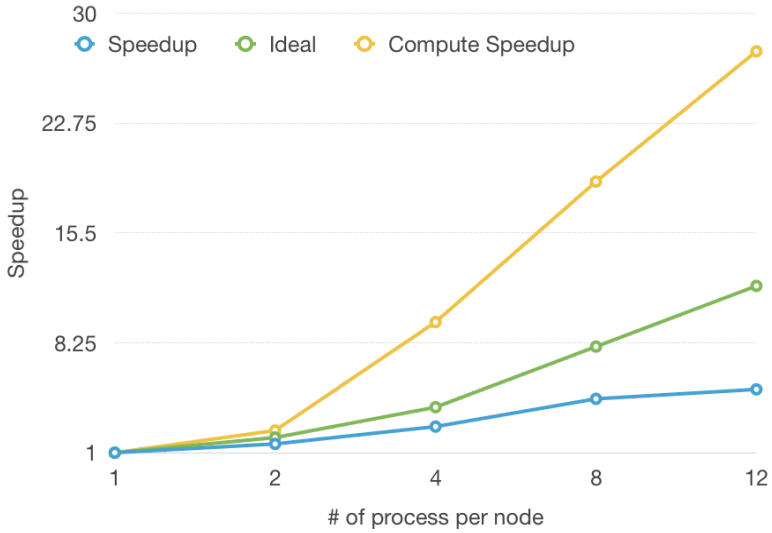

從實驗數據推測以下：

1. **整體 Speedup (藍線) 無法達到 Ideal 情況(綠線)**：雖然隨著 Process 數量增加，Computation time 也有逐步降低，但 I/O Time 與 Communication Time 並無法有效提升，導致 Speedup 並無法完全如預期。
2. **Computation 的 speedup 高於預期**：在 Multi-Nodes 時，computation 的加速大致與 ideal 的情況貼近，但在 single node 的情況下，Computation 的加速

遠大於 ideal 的情況。個人推測可能的原因在於，相同資料在記憶體容易存取，讓計算時更快。

Overall - Bottleneck

整合以上數據，由於 I/O 與 communication time 皆無法成比例的有效提升效率，此兩者為平行計算中最大的 bottleneck 。若想有效降低 communication time ，也許可透過 Non-blocking 的方式傳遞訊息，讓 computing time 與 communication time 得以在某些時候 overlap 。然則，為求測資的穩定性，本次實作仍選擇以較安全的 Blocking communication `(MPI_Sendrecv)`進行溝通。

Relationship between data intensive & communication time

	Communication Time	I/O Time
10^4	0.000090	0.004608
10^5	0.000846	0.006554
10^6	0.007058	0.013125
10^7	0.054665	0.028684
10^8	3.271073	0.597786

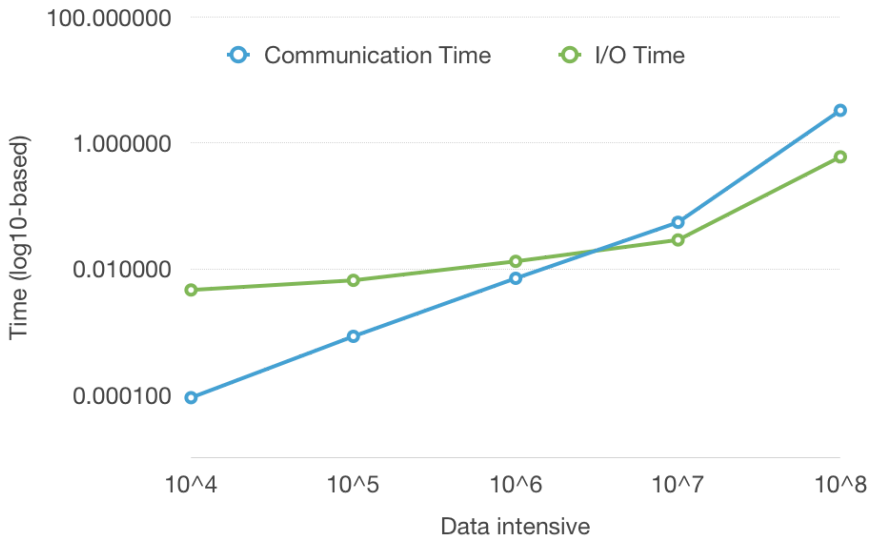

在不同的資料密集度下，除了直觀的 I/O time 會與 data 量呈現正比，MPI Communication Time 與 data 量也會有密切正比關係。也因此，傳輸的量多寡是決定 Communication time 的關鍵。

Conclusion

本次實作對於 MPI 系列有較多的了解。同時在整理數據時，才了解到如何展現實驗成果，用數據化的方式展現優化表現，甚至稍微整理實驗數據後，可以獲得新的認知及改進方向。同時，整體優化的過程也曠日費時，有時直覺想像中可優化的實作，數據上不一定也能呈現優化，不過過程中對 C 也有更深度的了解。同時也感謝 judge 團隊，輸入完 command 就能自動跑完測資也蠻神的。